

Criterios de detención por debajo del piso de señal-ruido: la longitud de la ventana, no la tolerancia, gobierna la detección de convergencia en comparaciones de arquitecturas

Maximiliano Speranza
Investigador independiente
Argentina

Las comparaciones entre arquitecturas de modelado eficiente de secuencias suelen detener el entrenamiento con una regla de la forma “la mejora de la exactitud de validación en los últimos w pasos es menor que una tolerancia τ ”, y luego otorgan a cada arquitectura el presupuesto resultante. Analizamos una regla de ese tipo, pre-registrada y congelada con un DOI antes de recolectar datos, y mostramos que no podía detectar convergencia: no porque su tolerancia estuviera mal calibrada, sino porque la decisión de detención se tomaba por debajo del piso de señal-ruido de la medición. En una tarea de recuperación asociativa multiconsulta, la condición de atención lineal con regla delta mejoraba a razón de 0.31 puntos de exactitud por evaluación en el régimen tratado como meseta (pendiente positiva en siete de ocho semillas; $t = 4.20$, $p = .004$), mientras que el ruido de la diferencia evaluada era de 1.16 puntos, lo que da una relación señal-ruido de 0.27. Bajo esa relación ninguna tolerancia separa los dos errores de interés: las reglas que detectan una meseta también detienen el entrenamiento durante una mejora genuina. Mostramos que un remedio propuesto —medias de ventana con tolerancia calibrada al ruido— tiene una tasa de detección fijada algebraicamente en $\Phi(2)$ con independencia de la ventana, y habría declarado convergencia mientras el modelo aún mejoraba con probabilidad .73. Al descomponer la ganancia alcanzable, un factor de 7.0 proviene de alargar la ventana de comparación y solo 1.31 de reemplazar la diferencia de dos puntos por una prueba de tendencia. La falla depende de la arquitectura: las condiciones que saturan exhiben un ruido tres órdenes de magnitud menor y cierran de inmediato, de modo que el presupuesto compartido covaría con la cantidad que se compara. Ofrecemos una regla basada en potencia para elegir w , pre-registrable sin datos piloto. Todos los análisis reutilizan historiales de validación ya almacenados y no requieren entrenamiento adicional.

Palabras Claves: criterio de detención, detención temprana, potencia estadística, pre-registro, atención lineal, recuperación asociativa, presupuesto de entrenamiento, reproducibilidad

Introducción

Las comparaciones entre arquitecturas de modelado eficiente de secuencias descansan sobre una decisión que rara vez se examina: cuándo detener el entrenamiento. Una práctica habitual consiste en entrenar una arquitectura de referencia hasta que se dispare una regla de convergencia y luego otorgar a cada arquitectura competidora el mismo número de pasos (Li et al., 2019). El procedimiento es válido solo si la convergen-

cia puede detectarse de manera confiable. Si la detección no lo es, el presupuesto compartido hereda esa falta de confiabilidad, y la comparación también.

Este artículo reporta un caso en el que la detección era imposible por construcción, y caracteriza por qué. El escenario es una comparación pre-registrada de composiciones de cabezas de atención sobre recuperación asociativa multiconsulta (MQAR, por sus siglas en inglés; Arora et al., 2023). La regla de detención fue es-

pecificada, congelada y publicada con un DOI antes de entrenar modelo alguno. Eso importa para el argumento que se desarrolla aquí: el defecto no puede atribuirse a una regla elegida después de ver los resultados, porque la regla no pudo haberse elegido después de verlos.

Nuestro diagnóstico difiere del que sugeriría inspeccionar la regla por sí sola. La tolerancia era, en efecto, menor que el ruido de la métrica, y resulta tentador concluir que la regla medía entonces ruido en lugar de convergencia. Esa conclusión no sobrevive al contacto con los datos. El régimen al que se aplicó la regla no era una meseta: la arquitectura de interés aún mejoraba, a una tasa que una ventana más larga habría detectado. La regla falló porque la *decisión de detención* se tomaba por debajo del piso de señal-ruido de la medición, y ninguna elección de tolerancia repara una decisión tomada bajo ese piso.

Nuestra contribución tiene cuatro partes. Primero, mostramos que el régimen tratado como convergido contenía una tendencia de mejora estadísticamente detectable, de modo que el diagnóstico debe formularse en términos de señal-ruido y no de tolerancia. Segundo, mostramos que recalibrar la tolerancia al ruido medido —el remedio natural— produce una tasa de detección fijada algebraicamente e independiente de la ventana, y compra poder de detección al costo de detenerse durante una mejora genuina. Tercero, descomponemos la ganancia alcanzable y encontramos que la longitud de la ventana domina a la elección del estadístico por un factor de cinco. Cuarto, mostramos que el ruido que impul-

sa todo esto depende de la arquitectura, lo que convierte una elección procedimental aparentemente neutra en una variable de confusión alineada con la variable bajo estudio, y ofrecemos una regla basada en potencia para w que es pre-registrable sin datos piloto.

El escenario pre-registrado

El experimento compara tres composiciones de cabezas en un transformer pequeño (193 493 parámetros) sobre MQAR: `softmax` (atención estándar), `delta` (atención lineal con regla delta) y `mix22` (dos cabezas `softmax` y dos cabezas `delta` en la misma capa). La atención lineal con regla delta actualiza un estado asociativo de tamaño fijo corrigiendo la lectura actual antes de escribir (Yang et al., 2024); se sabe que las composiciones híbridas recuperan capacidad de recuerdo que las variantes puramente lineales no alcanzan (Arora et al., 2023, 2024).

La exactitud de validación se evaluó cada 500 pasos como la media de la exactitud top-1 sobre las cargas {64, 96, 128}, con un conjunto de validación mantenido fijo entre evaluaciones mediante una semilla aleatoria fija. La regla pre-registrada, denominada D-004, declara convergencia en el paso N cuando

$$\text{exac}(N) - \text{exac}(N - w) < \tau, \quad (1)$$

con $w = 500$ y $\tau = 0.005$. Como las evaluaciones están separadas por 500 pasos, la Ecuación 1 compara dos evaluaciones *consecutivas*. Una condición cierra su primera fase de entrenamiento solo cuando las ocho semillas satisfacen la Ecuación 1; de lo contrario el entrenamiento continúa en bloques de 2 500 pasos hasta un tope de 10 000. El presupuesto común para la tabla de comparación primaria es entonces el máximo de los puntos de convergencia por condición, de modo que el comportamiento de detención de una condición fija el presupuesto otorgado a todas.

Método

Todos los análisis reutilizan historiales de validación almacenados durante la campaña original; ningún modelo fue reentrenado. Los datos comprenden ocho corridas de `delta`, ocho de `mix22` y tres de `softmax`, más una semilla de `delta` extendida a 10 000 pasos que se emplea solo donde se indica.

✉ Maximiliano Speranza Este trabajo se realizó de manera independiente, sin afiliación institucional, supervisión ni financiamiento. El autor es estudiante de la Tecnicatura Universitaria en Programación (TUP) de la Universidad Tecnológica Nacional (UTN), Argentina, y egresado de su Diplomatura en Inteligencia Artificial; ninguna de las dos carreras auspició ni supervisó este estudio, que se reporta aquí a título personal. La correspondencia relativa a este artículo debe dirigirse a Maximiliano Speranza. Correo electrónico: maximiliano.speranza@gmail.com. El criterio de detención analizado aquí fue pre-registrado y congelado con un DOI *antes* de recolectar dato alguno, lo que descarta la selección post hoc del criterio como explicación del defecto que se reporta. El autor declara no tener conflictos de interés y no haber recibido financiamiento para este trabajo. El código, los historiales de validación almacenados y el script de análisis están disponibles públicamente (véase Prácticas Abiertas).

Estimación del ruido y de la tendencia

Para cada corrida aislamos el régimen tardío de entrenamiento —desde el paso 4 000 para `delta` y 1 000 para las condiciones que saturan— y ajustamos una recta por mínimos cuadrados de la exactitud de validación contra el índice de evaluación. Estimamos el ruido por dos métodos: la desviación estándar de los residuos de ese ajuste, y la desviación estándar de las diferencias sucesivas dividida por $\sqrt{2}$. El segundo es insesgado bajo una tendencia lineal y sirve, por lo tanto, como control del primero. La cantidad que gobierna la Ecuación 1 es la desviación estándar de la diferencia evaluada, $\sigma_D = \sigma \sqrt{2}$.

La tendencia se contrasta por corrida mediante la pendiente b de mínimos cuadrados frente a $H_0: b = 0$, a una cola, y entre corridas mediante una prueba t de una muestra sobre las ocho pendientes.

Probabilidad de detección

Reportamos dos estimaciones. La estimación paramétrica modela las observaciones tardías como $\text{exac}(N) = \mu + \varepsilon$ con $\varepsilon \sim N(0, \sigma^2)$, lo que da $P = \Phi(\tau/\sigma_D)$ para una semilla y P^k para k semillas independientes. La estimación no paramétrica aprovecha que la Ecuación 1, con w igual al intervalo de evaluación, es una diferencia sucesiva: reportamos entonces la fracción observada de diferencias sucesivas menores que τ , lo que no exige supuesto distribucional alguno ni supuesto de independencia.

Resultados

El ruido de la métrica depende de la arquitectura

La Tabla 1 reporta el ruido tardío por condición. Los dos estimadores coinciden dentro del 1 %, lo que además indica que la autocorrelación residual es despreciable (véase Control de supuestos). La cantidad decisiva es τ/σ_D : por debajo de 1, la tolerancia no puede resolver el ruido de la cantidad contra la que se la compara.

Las tres condiciones difieren en σ por unos tres órdenes de magnitud. Una única tolerancia fija resulta así altamente informativa para dos de ellas e inservible para la tercera.

Tabla 1

Ruido tardío de la exactitud de validación por condición

Cond.	n	σ_{resid}	σ_{dif}	σ_D	τ/σ_D
<code>delta</code>	8	0.00821	0.00829	0.01162	0.43
<code>mix22</code>	8	0.00004	0.00004	0.00006	86.9
<code>softmax</code>	3	0.00004	0.00004	0.00006	88.8

Nota. $\sigma_D = \sigma_{\text{resid}} \sqrt{2}$ es la desviación estándar de la diferencia evaluada por la Ecuación 1. Las estimaciones usan ocho evaluaciones tardías por corrida para `delta` y cuatro para las condiciones que saturan; los cocientes de estas últimas deben leerse como “dos órdenes de magnitud o más”, no como valores precisos.

El régimen no es una meseta

Antes de preguntar si la regla detecta convergencia, preguntamos si había convergencia que detectar. La Tabla 2 contrasta la tendencia en el régimen al que se aplicó la regla.

Tabla 2

Prueba de tendencia en el régimen tratado como convergido (pasos 4 000–7 500)

Semilla	b	t	p	Mejora	D-004
0	+0.00259	1.86	.056	+1.81	sí
1	+0.00234	1.72	.068	+1.64	no
2	+0.00421	2.54	.022	+2.95	sí
3	+0.00334	5.12	.001	+2.34	no
4	−0.00014	−0.12	.547	−0.10	sí
5	+0.00445	3.58	.006	+3.11	no
6	+0.00141	1.37	.110	+0.98	sí
7	+0.00680	4.13	.003	+4.76	no

Nota. b es la pendiente de mínimos cuadrados por evaluación; los valores p son a una cola contra $H_0: b = 0$. “Mejora” es el incremento ajustado en puntos de exactitud a lo largo de los 3 500 pasos de la ventana. La última columna indica si la Ecuación 1 declaró convergencia en el paso 7 500.

La pendiente es positiva en siete de ocho semillas, con media +0.00312 por evaluación; una prueba t de una muestra sobre las ocho pendientes rechaza el cero, $t(7) = 4.20$, $p = .004$. Extrapolar la pendiente media predice +1.56 puntos de exactitud entre los pasos 7 500 y 10 000. La única semilla efectivamente extendida a

10 000 ganó +1.39 puntos de capacidad en la carga 96 (0.9167 $\rightarrow$ 0.9306), en concordancia con la proyección.

Esto reencuadra el problema. La condición *delta* no había convergido a los 7 500 pasos. Llevarla al tope de pasos no fue un artefacto de una regla ruidosa: fue el resultado correcto alcanzado por la razón equivocada. No puede reprochársele a la regla no haber detectado una convergencia que no había ocurrido, pero tampoco puede acreditársele nada, puesto que la Tabla 2 muestra que sus clasificaciones no guardan relación confiable con la tendencia medida.

La decisión se toma por debajo del piso de señal-ruido

Ahora pueden compararse las dos cantidades de manera directa. La señal disponible para la Ecuación 1 es un intervalo de evaluación de mejora, $b = 0.00312$; el ruido de la diferencia evaluada es $\sigma_D = 0.01162$. Su cociente es

$$\text{SNR} = \frac{b}{\sigma_D} = 0.27. \quad (2)$$

Este único número gobierna todo lo que sigue. Una regla de detención debe equilibrar dos errores: seguir entrenando después de la convergencia, y detenerse cuando aún queda mejora. Con $\text{SNR} < 1$ las dos tasas de error no pueden separarse mediante ninguna elección de τ , porque las distribuciones que se discriminan se solapan casi por completo. La selección de la tolerancia no es la palanca; solo desliza una frontera de decisión a lo largo de un eje sobre el cual las dos hipótesis no son distinguibles.

Probabilidad de detección

Para *delta*, el modelo paramétrico da $P = \Phi(0.43) = .667$ por semilla y $P^8 = .039$ para las ocho simultáneamente. La estimación no paramétrica —la fracción observada de diferencias sucesivas menores que τ en el mismo régimen, $N = 56$ — da $P = .554$, IC 95 % [.423, .684], y $P^8 = .009$. La estimación no paramétrica es preferible: no supone nada y ajusta mejor a lo observado. Cuatro de ocho semillas fueron clasificadas como convergidas; el conteo esperado es 4.4 bajo la estimación no paramétrica ($P(X \leq 4) = .52$) frente a 5.3 bajo la paramétrica ($P(X \leq 4) = .26$).

En cualquiera de los dos casos, la condición tenía menos de un 4 % de probabilidad de cerrar alguna vez

su fase por convergencia, lo que aquí es el resultado correcto —puesto que no había convergido—, pero habría sido igualmente cierto si hubiera convergido.

Recalibrar la tolerancia no resuelve el problema

El remedio natural consiste en comparar medias de ventana en lugar de puntos, y fijar la tolerancia a partir del ruido medido:

$$\overline{\text{exac}}_{\text{últimas } m} - \overline{\text{exac}}_{\text{previas } m} < c \sigma_D^{(m)}, \quad \sigma_D^{(m)} = \sigma \sqrt{2/m}. \quad (3)$$

Con $m = 3$ y $c = 2$, la probabilidad de detección conjunta sube de .039 a .832. Esa cifra no es evidencia de una regla mejor. Fijar la tolerancia en $c \sigma_D^{(m)}$ hace que la tasa de detección por semilla sea igual a $\Phi(c)$ idénticamente, para cualquier m y cualquier σ : con $c = 2$ vale $\Phi(2) = .977$ sea cual fuere la ventana. La Tabla 3 separa los dos ingredientes sobre nuestros datos. Toda la ganancia proviene de relajar la tolerancia, no de promediar en ventanas.

El costo de esa relajación es el error que la tasa de detección no mide. Bajo una tasa de mejora real b , la probabilidad de que la Ecuación 3 declare convergencia de todos modos es $\Phi(c - b m / \sigma_D^{(m)})$. A la tasa de mejora efectivamente medida, esa probabilidad es .73: la regla propuesta habría detenido a *delta* mientras aún ganaba alrededor de un punto de exactitud por ventana. Su mejora mínima detectable, con una tasa de detención espuria del 5 %, es de 4.07 puntos por bloque de 2 500 pasos: mayor que la ganancia de 1.39 puntos que la semilla extendida realizó efectivamente en un bloque de ese tamaño. Una regla ajustada para detectar mesetas de manera confiable en este régimen es, necesariamente, una regla que se detiene durante el progreso real.

La longitud de la ventana domina al estadístico

Lo que sí eleva el piso es la ventana. Para n evaluaciones equiespaciadas, la pendiente de mínimos cuadrados tiene error estándar

$$\text{EE}(b) = \sigma \sqrt{\frac{12}{n(n^2 - 1)}}, \quad (4)$$

que decrece como $n^{-3/2}$, frente a $n^{-1/2}$ del promediado. En nuestros datos, con $n = 8$ evaluaciones, $\text{EE}(b) = 0.00127$ y la pendiente media medida arroja $t = 2.46$: los mismos ocho puntos que dejan a la Ecuación 1 en

Tabla 3*Descomposición de la ganancia en detección*

Variante	τ	σ_D	P^8
D-004 tal como se pre-registró	0.0050	0.01162	.039
Solo ventana ($m = 3$, τ fija)	0.0050	0.00671	.126
Solo tolerancia recalibrada ($2\sigma_D$)	0.0232	0.01162	.832
Ecuación 3 completa	0.0134	0.00671	.832

Nota. P^8 es la probabilidad de que las ocho semillas sean declaradas convergidas simultáneamente estando en una meseta. Las dos últimas filas coinciden porque fijar $\tau = 2\sigma_D$ deja la tasa por semilla en $\Phi(2)$ con independencia de la ventana.

SNR = 0.27 sostienen la detección cuando se los usa conjuntamente. La ganancia total de $9.2\times$ se descompone en $7.0\times$ por comparar puntos separados por siete evaluaciones en lugar de una, y $1.31\times$ por usar el estadístico de tendencia en lugar de la diferencia entre extremos. La longitud de la ventana —no la elección del estadístico ni la tolerancia— es el término dominante.

De aquí se obtiene una regla que puede fijarse de antemano. Dada una tasa mínima de mejora b^* que el estudio se compromete a no pasar por alto, un nivel α a una cola y una potencia $1 - \beta$, la ventana debe satisfacer

$$b^* \geq (z_\alpha + z_\beta) \sigma \sqrt{\frac{12}{n(n^2 - 1)}}. \quad (5)$$

La Tabla 4 evalúa la Ecuación 5 al nivel de ruido medido aquí. Muestra lo que el diseño original habría requerido: detectar una mejora de un punto de exactitud por cada 2 500 pasos exige unas once evaluaciones, mientras que D-004 usó dos.

La Ecuación 5 requiere σ , que no se conoce antes de entrenar. Dos caminos evitan la circularidad. Cuando el conjunto de validación se remuestrea en cada evaluación, el error de muestreo aporta una cota inferior analítica, $\sigma \geq \sqrt{p(1-p)/n_{\text{val}}}$, calculable en tiempo de diseño. Cuando se lo mantiene fijo, como aquí, ese término se anula y el ruido residual es variabilidad del optimizador, que debe medirse; basta un piloto corto sobre cualquiera de las condiciones y, a diferencia de recalibrar una tolerancia después de ver los resultados, lo que se fija es una ventana, no un veredicto.

Propagación al presupuesto de entrenamiento

Como la regla fija el presupuesto común, su dependencia de la arquitectura no es neutra. Las condiciones

Tabla 4*Mejora detectable en función de la longitud de la ventana*

n	Ventana	EE(b)	b^*
4	1 500	0.00367	4.56
6	2 500	0.00196	2.44
8	3 500	0.00127	1.58
10	4 500	0.00090	1.12
12	5 500	0.00069	0.85
16	7 500	0.00045	0.55
20	9 500	0.00032	0.40

Nota. n = cantidad de evaluaciones en la ventana; “Ventana” es su extensión en pasos de entrenamiento. $\sigma = 0.00821$, $\alpha = .05$ a una cola, potencia = .80. b^* es la mínima tasa de mejora detectable con esa potencia, en puntos de exactitud por cada 2 500 pasos.

que saturan tienen $\tau/\sigma_D \approx 87$ y cierran en la primera oportunidad; la condición que no satura aún mejora y es llevada al tope. Cualquiera sea el presupuesto que se adopte entonces, o bien resulta insuficiente para la condición que sigue aprendiendo, o bien excede con creces lo que necesitan las que saturan, y *cuál de las dos cosas ocurre lo deciden las condiciones que saturan*. El presupuesto otorgado covaría así con el desempeño en la tarea: precisamente la cantidad bajo comparación.

La magnitud es relevante. El margen de decisión pre-registrado para la hipótesis primaria era de 2 puntos de exactitud; la semilla extendida de 7 500 a 10 000 pasos ganó 1.39 puntos de capacidad en la carga 96. Una diferencia inducida por el presupuesto del mismo orden que el margen de decisión no es una cuestión de redondeo. Esta estimación descansa sobre una única semilla ex-

tendida y es indicativa más que concluyente; el análisis de tendencia de la Tabla 2, que usa las ocho, respalda la misma dirección y magnitud.

Control de supuestos

Autocorrelación residual. La autocorrelación de rezago 1 de los residuos sin tendencia es negativa en siete de ocho corridas, con mediana -0.315 , lo que invita a corregir $\text{Var}(D)$. La corrección sería espuria. Con $n = 8$ puntos y una tendencia ajustada removida, el estimador de rezago 1 está fuertemente sesgado hacia abajo incluso bajo ruido blanco: una simulación bajo ruido blanco (20 000 réplicas) da $E[\hat{\rho}_1] = -0.287$, con intervalo del 95 % $[-0.803, +0.310]$, lo que ubica la mediana observada en el percentil 49 de la distribución nula. Este es el sesgo de muestra pequeña de los estimadores de autocorrelación (Marriott & Pope, 1954). Los datos contienen un control independiente: si $\rho_1 = -0.315$ fuera real, $\sigma_{\text{dif}}/\sigma_{\text{resid}}$ debería valer $\sqrt{1 - \rho_1} = 1.147$; el cociente observado es 1.010, lo que implica $\rho_1 = -0.02$. Tratamos entonces a los residuos como serialmente no correlacionados. Señalamos el punto porque la corrección tentadora corre en la dirección que favorece al argumento, y se habría reportado como respaldo suyo.

Origen del ruido. El conjunto de validación se mantiene fijo entre evaluaciones mediante una semilla fija y comprende alrededor de 37 000 consultas; el error de remuestreo aportaría $\sigma \approx 0.0018$ y, al estar fijo, no aporta nada. El $\sigma = 0.0082$ medido es por lo tanto atribuible a la variabilidad del optimizador y no al error de medición. Agrandar el conjunto de validación no lo reduciría; promediar en el tiempo o promediar pesos, sí.

Elección del inicio del régimen. Variar el inicio entre los pasos 2 500 y 5 000 deja τ/σ_D entre 0.39 y 0.51, siempre muy por debajo de la unidad, y no altera el signo ni la significación de la tendencia.

¿Sigue la exactitud de validación a la cantidad de interés? Entre las ocho semillas de delta, la exactitud de validación final correlaciona con la capacidad en la carga 96 a $r = .96$ y en la carga 128 a $r = .99$. La métrica no es ciega al eje bajo estudio; es ruidosa en relación con su propia tasa de cambio. El problema es de potencia, no de constructo.

Discusión

Implicancias

El costo práctico de una regla de detención por debajo del piso de ruido no es en primer lugar el cómputo desperdiciado, aunque en nuestra campaña alrededor del 80 % del presupuesto proyectado era atribuible a ella. El costo serio es que el presupuesto de entrenamiento pasa a ser función del ruido de la métrica, que a su vez es función de dónde se sitúa la arquitectura respecto de la tarea. Las arquitecturas que saturan se detienen temprano; las que están en el régimen intermedio interesante son llevadas al tope. Toda comparación trazada a través de esa asimetría queda confundida, y la confusión está alineada con la variable que el estudio existe para medir.

El episodio deja además una lección sobre el pre-registro. Congelar una regla de detención es buena práctica, pero una regla congelada sin análisis de potencia congela un supuesto no examinado sobre el ruido de la métrica. Nuestro pre-registro fijó τ y w y no dijo nada sobre σ ; lo que debería haberse registrado en su lugar es la Ecuación 5, puesto que enuncia qué se compromete el estudio a detectar en vez de cómo calculará una diferencia. Este es el análogo, para las decisiones tomadas durante el entrenamiento, de registrar un tamaño de efecto objetivo en lugar de un umbral de p .

Relación con trabajos previos

Que la detención temprana basada en validación es inestable en regímenes ruidosos está establecido (Prechelt, 1998), como lo está la necesidad de controlar el presupuesto de entrenamiento al comparar arquitecturas (Li et al., 2019), y se ha mostrado que el ruido de muestreo de semillas afecta la confiabilidad de los *benchmarks* sintéticos (Chanin, 2026). La contribución específica de este trabajo es la cadena que los vincula y su cuantificación: una decisión de detención tomada por debajo del piso de señal-ruido, un piso que difiere en tres órdenes de magnitud entre las arquitecturas comparadas, y una regla de presupuesto que transmite esa diferencia a la comparación. Reportamos además, como detalle de advertencia, que las dos reparaciones naturales —recalibrar la tolerancia al ruido medido y promediar sobre una ventana— atacan el término menor y dejan intacto el dominante.

Limitaciones

Este es un caso único documentado, no un estudio general. Involucra una familia de tareas (MQAR), una escala de modelo (193K parámetros), una plataforma de hardware, tres condiciones y ocho semillas por condición. No afirmamos que las reglas de tolerancia fija fallen en general, ni que algún resultado publicado quede invalidado por este mecanismo. La estimación del efecto de presupuesto en la carga 96 descansa sobre una única semilla extendida; el análisis de tendencia que la corrobora usa las ocho, pero extrapola más allá del rango observado. La regla de potencia de la Ecuación 5 supone una tendencia de mejora aproximadamente lineal y ruido homocedástico a lo largo de la ventana, lo que es una aproximación para la dinámica tardía de entrenamiento y fallaría cerca de una transición abrupta. Por último, la Ecuación 5 se deriva aquí y se valida solo de manera retrospectiva; su validación prospectiva queda como trabajo futuro y es el paso natural siguiente de esta línea.

Recomendaciones

Sugerimos cuatro prácticas económicas. Primera: antes de fijar una regla de detención, enunciar la mínima tasa de mejora que el estudio se compromete a detectar, y dimensionar la ventana a partir de ella con la Ecuación 5; reportar la potencia resultante. Segunda: reportar τ/σ_D y no τ a secas, puesto que la tolerancia es interpretable sin el ruido de la cantidad contra la que se la compara. Tercera: reportar el ruido por condición, ya que una regla adecuada para una arquitectura puede ser inservible para otra dentro del mismo estudio, y esa asimetría es una variable de confusión y no un inconveniente. Cuarta: cuando se relaje una regla para elevar su tasa de detección, reportar el error complementario —la probabilidad de detenerse ante la mínima mejora que importa—, porque la tasa de detección por sí sola siempre puede llevarse al valor que se desee.

Conclusión

Una regla de detención compara una mejora contra una tolerancia, pero lo que determina si puede funcionar no es ninguna de esas cantidades por separado: es el cociente entre la mejora acumulada a lo largo de la ventana de comparación y el ruido de esa comparación.

Cuando ese cociente está por debajo de la unidad, la regla informa hacia qué lado cayó la última evaluación, y ninguna tolerancia recupera la decisión. Alargar la ventana sí lo hace, y a una tasa que vuelve barata la corrección. Cuando una regla así fija además el presupuesto de entrenamiento compartido de una comparación entre arquitecturas, su sensibilidad al ruido —dependiente de la arquitectura— convierte una elección procedimental en una variable de confusión alineada con la variable bajo estudio. Diagnosticarlo no requirió nada más que los historiales de validación que ya se estaban almacenando, y corregirlo no requiere entrenamiento adicional.

Prácticas Abiertas

El pre-registro fue congelado y publicado antes de la recolección de datos (DOI: 10.5281/zenodo.21495252). El código, los historiales de validación almacenados y el script de análisis que reproduce las cifras reportadas están disponibles en <https://github.com/SperanzaMax/telar-ligamento>; el análisis corre en CPU en menos de un minuto. Debe consignarse una excepción: la única semilla de Δ extendida a 10 000 pasos, citada una vez por su ganancia de capacidad de 1.39 puntos, se perdió por una caída de sesión antes de poder versionarse, y es la única cantidad de este artículo que no puede recomputarse desde el repositorio. Toda otra cifra, incluido el análisis de tendencia que predice esa ganancia de manera independiente, se deriva de las ocho corridas versionadas.

Referencias

- Arora, S., Eyuboglu, S., Timalsina, A., Johnson, I., Poli, M., Zou, J., Rudra, A., & Ré, C. (2023). Zoology: Measuring and Improving Recall in Efficient Language Models. <https://doi.org/10.48550/arXiv.2312.04927>
- Arora, S., Eyuboglu, S., Zhang, M., Timalsina, A., Alberti, S., Zinsley, D., Zou, J., Rudra, A., & Ré, C. (2024). Simple linear attention language models balance the recall-throughput tradeoff. <https://doi.org/10.48550/arXiv.2402.18668>
- Chanin, D. (2026). Are Sparse Autoencoder Benchmarks Reliable? <https://doi.org/10.48550/arXiv.2605.18229>

- Li, M., Yumer, E., & Ramanan, D. (2019). Budgeted Training: Rethinking Deep Neural Network Training Under Resource Constraints. <https://doi.org/10.48550/arXiv.1905.04753>
- Marriott, F. H. C., & Pope, J. A. (1954). Bias in the estimation of autocorrelations. *Biometrika*, 41(3–4), 390-402. <https://doi.org/10.1093/biomet/41.3-4.390>
- Prechelt, L. (1998). Automatic early stopping using cross validation: Quantifying the criteria. *Neural Networks*, 11(4), 761-767. [https://doi.org/10.1016/S0893-6080\(98\)00010-0](https://doi.org/10.1016/S0893-6080(98)00010-0)
- Yang, S., Kautz, J., & Hatamizadeh, A. (2024). Gated Delta Networks: Improving Mamba2 with Delta Rule. <https://doi.org/10.48550/arXiv.2412.06464>