

Una cabeza *softmax* de cada cuatro restituye la recuperación en el techo: una replicación pre-registrada con un efecto censurado y una frontera inalcanzable

Maximiliano Speranza
Investigador independiente
Argentina

Las arquitecturas de atención lineal cambian el costo cuadrático de la atención *softmax* por un estado recurrente de tamaño fijo, y lo pagan con un techo de capacidad en recuperación asociativa. Hibridar ambos mecanismos a lo largo del eje de cabezas es un remedio ya establecido. Reportamos una replicación pre-registrada que lo cuantifica, y dos resultados que el pre-registro nos obligó a enunciar en contra de nuestro propio interés. Primero: en un banco de recuperación asociativa multiconsulta con $d_{\text{model}} = 64$ y cuatro cabezas, la condición de regla delta cae a .921 y .820 de exactitud en las cargas 96 y 128, mientras que todas las condiciones híbridas se mantienen en 1.000; la diferencia apareada en la carga de evaluación pre-registrada es +.0792, IC del 95 % [+0.0747, +.0838], cuatro veces el margen pre-registrado, positiva en ocho de ocho semillas. Segundo: la dosis mínima probada —una cabeza *softmax* de cada cuatro— ya restituye el techo (peor celda: déficit de 1.22×10^{-4}), de modo que la afirmación sobre la mezcla de dos cabezas es de *suficiencia, no de necesidad*, y el costo del remedio queda acotado por arriba en un cuarto de las cabezas. Y algo decisivo: el efecto está *censurado*. Todas las condiciones híbridas saturan, así que +.0792 es una cota inferior y el enunciado medido es sobre la regla delta —*cae por debajo del techo en cargas donde las híbridas no caen*—, no sobre cuánto mejores son las híbridas. Una calibración pre-registrada buscó luego un régimen con rango dinámico, y fracasó bajo sus propias reglas: duplicar el conjunto de claves y la carga dejó a la condición de referencia en 1.000, de modo que la frontera es inalcanzable a esta escala y la predicción de equivalencia a la que hubiera servido queda registrada como *no corrida*, nunca como confirmada. Sostenemos que el aporte durable es el pre-registro mismo, y reportamos el libro mayor de las conveniencias que rechazó.

Palabras Claves: atención lineal, recuperación asociativa, pre-registro, atención híbrida, efectos de techo, replicación

Introducción

La atención con núcleo *softmax* compara cada consulta contra cada clave, lo que cuesta $O(n^2)$ en longitud de secuencia pero no impone ninguna cota arquitectónica sobre cuántas asociaciones puede recuperar una capa. La atención lineal reemplaza esa comparación por un estado recurrente de tamaño fijo que se actualiza en línea, lo que cuesta $O(n)$ y sí impone esa cota: el estado tiene una cantidad finita de casilleros y, cuando el número de asociaciones almacenadas se acerca a esa cantidad, la recuperación se degrada. El compromiso está bien establecido, y también lo está el remedio de mez-

clar ambos mecanismos dentro de una capa (Arora et al., 2023, 2024; Yang et al., 2024). Desde entonces se demostró a escala: Tan et al. (2026) hibridan atención plena y lineal a lo largo del eje de cabezas y reportan mejoras grandes en contextos largos.

Este artículo no reclama el mecanismo como novedoso. Ya se conocía cuando nuestro protocolo se congeló, y Tan et al. (2026) apareció un mes antes. Lo que aportamos es una medición hecha bajo reglas escritas de antemano —algo poco frecuente en esta literatura— y tres consecuencias de tomarse esas reglas en serio:

1. El remedio satura en la dosis más chica que pro-

bamos —una cabeza de cada cuatro—, de modo que la mezcla habitual de dos y dos es suficiente pero no necesaria, y el precio del arreglo queda acotado por arriba en un cuarto de las cabezas.

2. El número principal está *censurado por un techo*, lo que cambia su significado. Reportamos el enunciado corregido y no el halagador.
3. Un intento pre-registrado de escapar del techo fracasó bajo sus propios criterios, y la predicción a la que hubiera servido queda registrada como no corrida.

Método

Pre-registro

El protocolo se congeló el 22-07-2026 (SHA-256 2f8ebb82...) y se depositó con un DOI antes de entrenar cualquier condición de comparación. Un pre-registro de seguimiento para la comparación que se reporta acá se congeló el 23-07-2026 (SHA-256 0b93a36f...) con una etiqueta firmada y una marca temporal del servidor anterior a toda corrida que gobierne. Dos enmiendas posteriores —una que agrega la condición de dosis mínima, otra que especifica la búsqueda de régimen— se congelaron, hashead y anclaron públicamente antes de la corrida que autorizan. Un script de compuerta re-hashea todos los artefactos congelados y se niega a lanzar si alguno difiere.

 Maximiliano Speranza Este trabajo se realizó de manera independiente, sin afiliación institucional, supervisión ni financiamiento. El autor es estudiante de la Tecnicatura Universitaria en Programación (TUP) de la Universidad Tecnológica Nacional (UTN), Argentina, y egresado de su Diplomatura en Inteligencia Artificial; ninguna de las dos carreras auspició ni supervisó este estudio, que se reporta aquí a título personal. La correspondencia relativa a este artículo debe dirigirse a Maximiliano Speranza. Correo electrónico: maximiliano.speranza@gmail.com. Cada predicción que se reporta acá fue pre-registrada y congelada con un hash criptográfico y una marca temporal pública *antes* de recolectar los datos correspondientes; las enmiendas que extendieron el protocolo se congelaron del mismo modo, cada una antes de la corrida que gobierna. El autor declara no tener conflictos de intereses y no recibió financiamiento. El código, los resultados crudos y los scripts de análisis que reproducen cada número son públicos (véase Prácticas abiertas).

Tarea y condiciones

El banco de pruebas es recuperación asociativa multiconsulta: una secuencia presenta L pares clave–valor seguidos de consultas, y el modelo debe devolver el valor ligado a cada clave consultada. La carga L es el número de pares almacenados; un conjunto de N_K claves aporta distractores que nunca aparecen. La exactitud es la coincidencia exacta en la primera posición candidata.

Todas las condiciones comparten una arquitectura (193 493 parámetros; $d_{\text{model}} = 64$, cuatro cabezas, RMSNorm por cabeza) y difieren únicamente en qué cabezas usan qué mecanismo: **softmax** (cuatro cabezas *softmax*), **delta** (cuatro cabezas de regla delta), **mix22** (dos y dos) y **mix13** (una cabeza *softmax* y tres de regla delta). Los conteos de parámetros son idénticos por construcción; los FLOPs no lo son, y no pueden serlo —*softmax* es $O(n^2)$ y la regla delta es $O(n)$ —, así que el pre-registro iguala parámetros, reporta FLOPs y declara la dirección del sesgo: las híbridas corren con *desventaja* de cómputo frente a *softmax* puro, lo que vuelve conservadora cualquier confirmación.

Márgenes, semillas y carga de evaluación

Ocho semillas por condición. El margen de equivalencia no es un número fijo sino una regla fijada de antemano: $R_{11} = \text{máx}(.02, 1.5 \times \text{SD entre semillas de la referencia})$, instanciada y registrada antes de inspeccionar cualquier condición de comparación; acá evalúa a .0200. Las diferencias se aparean por semilla. La carga de evaluación también se define por regla —la menor carga en la que la referencia cae por debajo del 95 %—, lo que arroja $L = 96$.

Se usa en todo el trabajo un esquema de tres veredictos: *diferencia*, *equivalencia* o *no concluyente*. Nunca se declara equivalencia ni diferencia por defecto.

Resultados

La regla delta cae por debajo del techo; ninguna híbrida lo hace

La Tabla 1 da la exactitud por carga con el presupuesto común.

La condición de regla delta es la única que abandona el techo, y lo hace de manera monótona con la carga. En la carga de evaluación pre-registrada, la diferencia apareada entre la mezcla de dos y dos y la regla delta es

Tabla 1

Exactitud (top-1) por carga, ocho semillas, presupuesto común $N = 10\,000$.

condición	L8	L16	L32	L64	L96	L128
delta	1.000	1.000	1.000	.985	.921	.820
softmax	1.000	1.000	1.000	1.000	1.000	1.000
mix22	1.000	1.000	1.000	1.000	1.000	1.000
mix13	1.000	1.000	1.000	1.000	1.000	1.000

+0.0792, IC del 95 % [+0.0747, +0.0838], que equivale a 4.0 veces el margen pre-registrado de .0200 y es positiva en ocho de ocho semillas. La predicción se confirma en la tabla primaria y en la secundaria, y la regla de discordancia pre-registrada —que habría degradado el veredicto si ambas tablas discrepaban— no se activó. Una reimplementación independiente del estadístico, escrita sin importar nada del código de análisis y usando solo la biblioteca estándar, reproduce la media de forma exacta y el intervalo de confianza dentro del ruido de Monte Carlo.

Alcanza con una cabeza de cada cuatro

La condición de dosis mínima se agregó mediante una enmienda congelada que llevaba una tabla de interpretación escrita *antes* de la corrida: cada resultado posible quedó mapeado de antemano a la afirmación que habilitaría. El resultado cayó en la fila donde la híbrida restituye el techo con la dosis más chica probada. Su peor celda en toda la grilla es un déficit de 1.22×10^{-4} respecto de la unidad —dentro de la tolerancia $R_{11}/10$ fijada para «estar en el techo»— y su diferencia apareada contra la regla delta en L96 es +0.0792, IC del 95 % [+0.0748, +0.0837], otra vez ocho de ocho semillas.

De ahí se siguen dos consecuencias, y la tabla congelada enuncia ambas:

- La afirmación sobre mix22 pasa a ser de **suficiencia, no de necesidad**. Dos cabezas *softmax* restituyen el techo, pero una también; el experimento no habilita a decir «hacen falta dos». El costo del remedio queda acotado por arriba en un cuarto de las cabezas.
- **No se obtiene curva dosis–respuesta**. Los tres puntos hibridados saturan, así que la predicción

de monotonía no puede evaluarse. Se reporta como no evaluable, no como confirmada.

Qué significa realmente el número: censura

Es tentador reportar +0.0792 como «la híbrida supera la regla delta por ocho puntos». Esa lectura es incorrecta, y fue el pre-registro lo que la detectó. Todas las condiciones híbridas están en el techo a largo de la grilla entera —la peor celda de mix22 en cualquier punto es .999512—. Su capacidad, por lo tanto, no está medida sino **censurada**: observamos que todavía no falló, no cuán lejos está de fallar. Un instrumento que satura no puede informar la magnitud de aquello que lo excede.

El enunciado medido es, en consecuencia, sobre la *regla delta*:

La regla delta por sí sola cae por debajo del techo en cargas donde las condiciones híbridas no caen.

y +0.0792 es una **cota inferior** de una diferencia cuyo valor real se desconoce y puede ser mucho mayor. Es una afirmación más débil sobre la híbrida de lo que sugiere el número crudo, y más filosa sobre la línea de base de atención lineal. Notamos, además, que es una afirmación distinta de las de la literatura híbrida a escala, que reporta ganancias en tarea final en vez de una cota sobre dónde falla primero una línea de base de atención lineal pura.

Predicciones secundarias

El estadístico descriptivo pre-registrado que ubica a la híbrida entre las dos condiciones puras da $f = (C_3 - C_2)/(C_1 - C_2) = 1.001$: la híbrida está exactamente en el techo de *softmax*, que es la censura de arriba dicha de otro modo.

La predicción sobre dónde comienza la degradación se confirma en sus tres partes: inicio en la mediana $L_0 = 64$; monotonía estricta de la degradación con la carga ($\rho = -1.000$); y decaimiento acelerado en vez de lineal (+0.0361, IC del 95 % [+0.0335, +0.0390]).

La predicción de una anticorrelación entre capacidad y corregibilidad es **no concluyente** y así se reporta. Su prueba prevista no era evaluable en la carga de evaluación (la SD de la referencia quedó por debajo del umbral de usabilidad pre-registrado), de modo que se apli-

có el respaldo pre-especificado, lo que vuelve la comparación cruzada entre cargas; la correlación resultante es $-.455$ con un intervalo de confianza que cruza el cero. Un diagnóstico pre-registrado justamente para esto descarta el confundido del punto de detención como explicación, y deja a la potencia estadística como limitación. Con ocho semillas el estudio no puede resolverla.

La frontera no es alcanzable a esta escala

La censura de arriba tiene un remedio evidente: encontrar un régimen donde la referencia tenga rango dinámico y volver a correr la comparación ahí. La regla para elegir ese régimen se congeló antes de que existiera cualquier dato de calibración. Especifica una banda objetivo para la exactitud de la referencia $-.50, .80]$, donde el borde superior es $1 - 10R_{11}$ y no una cuestión de gusto—, un espacio de búsqueda enumerado y ordenado de dos regímenes, un presupuesto de cómputo partido en dos mitades declaradas y cuatro ramas de salida exhaustivas.

Se corrieron los dos escalones. El primero ($N_K = 256, L \leq 128$) devolvió 1.000 en todas las cargas. El segundo ($N_K = 512, L \leq 256$) —el doble de claves y el doble de carga, reentrenado desde cero— devolvió los valores de la Tabla 2: sigue en el techo en todas partes, peor celda .9999.

Tabla 2

Exactitud de la referencia en el segundo escalón de calibración ($N_K = 512$).

L	8	16	32	64	96	128	192	256
acc@1	1.000	1.000	.9999	1.000	1.000	1.000	1.000	.9999

Con los dos escalones cerrados y ninguno dentro de la banda, el procedimiento de decisión congelado emite su tercera rama: la frontera queda más allá de lo que este presupuesto puede medir a este d_{model} . Las consecuencias estaban escritas de antemano y son mecánicas. La predicción de equivalencia que requería un régimen no saturado se registra como **no corrida —nunca como confirmada—**, sobre la base explícita de que correrla en un régimen saturado produce un renglón que no puede fallar. Reducir d_{model} se deriva a una campaña futura como rediseño documentado, porque achicarlo rompe el invariante de «misma arquitectura» que vuelve com-

parables a las campañas entre sí.

Subrayamos la asimetría que vuelve esto reportable en vez de embarazoso. La rama no se eligió después de ver el resultado: era una de cuatro escritas antes de que existiera dato alguno de calibración, junto con la regla que la distingue de «se nos acabó el presupuesto» —una distinción que importó, porque una lectura anterior de la misma evidencia habría declarado inalcanzable la frontera con un escalón todavía sin correr—. Correrlo costó diecisiete minutos de una T4.

Una búsqueda exploratoria fuera del espacio congelado (variando d_{model} , reportada acá solo para documentar por qué no se prosigue) encontró que el régimen es degenerado y no meramente difícil: con $d_{\text{model}} = 8$ cada cabeza escribe en un estado de cuatro números, y la condición híbrida se vuelve *inestable en vez de incapaz* —alcanza un pico cercano a .52 y después colapsa—. Una comparación ahí mediría colapso numérico, no la hipótesis.

El libro mayor de las conveniencias

Si el aporte durable de este trabajo es el pre-registro y no el mecanismo, entonces la manera honesta de reportarlo es publicar lo que las reglas rechazaron, y no solo lo que permitieron. Listamos las decisiones en las que el protocolo congelado jugó en contra de nuestro interés.

- **Hubo que degradar un titular tentador.** «La híbrida le gana a la regla delta por ocho puntos» pasó a «la regla delta cae donde las híbridas no, por al menos ocho puntos», porque la híbrida estaba censurada.
- **Una afirmación de necesidad se volvió de suficiencia** cuando funcionó la dosis mínima, bajo una tabla de interpretación escrita antes de la corrida.
- **Una predicción se retiró en vez de reportarse.** Una regla de detención que habíamos propuesto habría frenado el entrenamiento mientras el modelo todavía mejoraba; se retiró y se reemplazó por una regla basada en potencia, declarada no retroactiva.
- **Una enmienda que eximia a una condición se reescribió** cuando una auditoría encontró que su

umbral excluía justamente a la condición para la que estaba escrita.

- **Un resultado no concluyente siguió siendo no concluyente.** La predicción de capacidad–corregibilidad podía haberse reportado como tendencia; su intervalo cruza el cero, así que se reporta con potencia insuficiente.
- **Se retiró la defensa de un resguardo** cuando se vio que comparaba un desplazamiento entre regímenes contra ruido dentro del régimen, y se la reemplazó por una defensa medida.

Vale registrar otras dos mediciones porque inciden en cómo deberían reportarse estas comparaciones. Primero, un criterio interno de detención —congelado con un DOI antes de recolectar datos— resultó luego indetectable en principio con la razón señal-ruido alcanzada (Speranza, 2026). Segundo, cambiar el *backend* de cómputo (CPU frente a una GPU T4), manteniendo fijos semilla, datos y código, mueve la exactitud de validación alrededor del 30 % del margen de decisión en el régimen tardío de entrenamiento. Los estudios que reportan «media $\pm$ SD sobre N semillas» omiten un término de orden comparable.

Limitaciones

La censura es la principal: la magnitud de la ventaja híbrida no está medida, solo acotada por abajo, y la calibración estableció que ningún régimen accesible remueve el techo en esta tarea a esta escala. El resultado, por lo tanto, se traslada a las otras dos tareas del programa solo como hipótesis —la regla congelada que gobierna la búsqueda de régimen lo dice explícitamente, ya que esas tareas tienen su propio nivel de azar y su propia dificultad—.

La predicción de anticorrelación tiene potencia insuficiente con ocho semillas. El presupuesto común de entrenamiento es declarado y no derivado: la condición de regla delta no había convergido en el tope pre-registrado en tres de ocho semillas, así que se reporta como presupuesto fijo declarado, lo que sesga en contra de esa condición y es por lo tanto conservador para la predicción

confirmada. Por último, este es un estudio de escala pequeña ($\sim 10^5$ parámetros, tarea sintética): cuantifica un mecanismo en condiciones controladas y no establece ganancias en tarea final a escala, para lo cual el lector debe remitirse a la literatura citada más arriba.

Prácticas abiertas

El protocolo congelado está depositado con un DOI (10.5281/zenodo.21495252). El pre-registro de seguimiento y todas las enmiendas son públicos, hashados, firmados y con marca temporal, cada uno anclado antes de la corrida que gobierna. Los resultados crudos por semilla, el código de análisis, una reimplementación independiente del estadístico principal y los registros de calibración están disponibles en <https://github.com/SperanzaMax/telar-ligamento>. Cada número de este artículo es reproducible a partir de los artefactos depositados; los scripts de análisis corren en CPU.

Referencias

- Arora, S., Eyuboglu, S., Timalsina, A., Johnson, I., Poli, M., Zou, J., Rudra, A., & Ré, C. (2023). Zooology: Measuring and Improving Recall in Efficient Language Models. <https://doi.org/10.48550/arXiv.2312.04927>
- Arora, S., Eyuboglu, S., Zhang, M., Timalsina, A., Alberti, S., Zinsley, D., Zou, J., Rudra, A., & Ré, C. (2024). Simple linear attention language models balance the recall-throughput tradeoff. <https://doi.org/10.48550/arXiv.2402.18668>
- Speranza, M. (2026). Stopping Criteria Below the Signal-to-Noise Floor: Window Length, Not Tolerance, Governs Convergence Detection in Architecture Comparisons [Preprint]. <https://doi.org/10.5281/zenodo.21630279>
- Tan, Z., Chen, W., Shen, J., Liu, Y., Shen, X., Wu, Y., & Ye, J. (2026). HydraHead: From Head-Level Functional Heterogeneity to Specialized Attention Hybridization [Submitted 18 June 2026].
- Yang, S., Kautz, J., & Hatamizadeh, A. (2024). Gated Delta Networks: Improving Mamba2 with Delta Rule. <https://doi.org/10.48550/arXiv.2412.06464>